Assistente Pessoal H.E.R.O. (J.A.R.V.I.S. Core)

Documentação Técnica & Arquitetural do Sistema Multi-Agente Stark
Autor: Douglas • **Arquitetura:** 100% Local, Privada e Reativa

1. Visão Geral do Ecossistema

O **Assistente Pessoal H.E.R.O.** é uma plataforma de inteligência artificial de voz e raciocínio multi-agente projetada para rodar com privacidade absoluta no hardware local (sem depender de APIs externas pagas). Integrado ao Docker e Ollama, oferece comunicação bidirecional com baixa latência, reator Arc com Web Audio API, memória semântica de longo prazo (PostgreSQL + pgvector) e troca automática de agentes baseada no contexto da conversa.

2. Protocolos de IA Especializados (VisionQuest)

Protocolo	Função Primária	Especialidades Técnicas	Voz Neural (PT-BR)
J.A.R.V.I.S.	Núcleo Central & Segurança	Coordenação dos protocolos, integridade de dados e proteção central.	pt-BR-Antonio
E.D.I.T.H.	Cibersegurança Virtual	Defesa virtual (Blue Team), auditoria de código, proteção contra SQLi/XSS/DDoS e pentests éticos (Red Team) em sites e apps.	pt-BR-Thalita
F.R.I.D.A.Y.	Socialização & Empatia	Inteligência relacional, condução de conversas difíceis, psicologia, aconselhamento empático e humor.	pt-BR-Francisca
D.U.M.-E & U	Manutenção & Mídia	**U:** análise técnica de mídia, vídeos e arquivos. **DUM-E:** faxina de cache, expurgo de logs e estabilidade.	pt-BR-Antonio

3. Pilares Técnicos de Engenharia

• **Roteamento Semântico Inteligente:** Não é obrigatório chamar o agente pelo nome. Ao perguntar sobre invasão, brechas ou segurança web, **E.D.I.T.H.** assume automaticamente com o HUD violeta. Temas relacionais ativam **F.R.I.D.A.Y.** e limpeza de sistema ativa **D.U.M.-E**.
• **Memória Semântica Vetorial (Hipocampo):** PostgreSQL 16 com extensão *pgvector* e embeddings locais *nomic-embed-text* (768 dimensões). Aprendizado de fatos em tempo real com prevenção de duplicação semântica.
• **Pipeline de Áudio de Baixa Latência:** Reconhecimento de fala via *faster-whisper* local (com VAD e pré-aquecimento assíncrono) e síntese *edge-tts* fragmentada por sentenças via WebSocket com suporte a *Barge-in* (interrupção imediata por fala ou tecla Esc).
• **HUD Futurista Reator Arc:** Desenvolvido em HTML5 Canvas, Web Audio API e glassmorphism reativo às frequências vocais.

Plano de Implementação Passo a Passo (Deploy Local)

Roteiro completo para replicação do Assistente H.E.R.O. em novos computadores ou servidores

Fase 1: Preparação do Ambiente Host

1. Docker Desktop: Instale o Docker e confirme que o motor WSL2 está ativado.
2. Ollama: Instale em ollama.com. Adicione a variável de ambiente do sistema OLLAMA_HOST=0.0.0.0 e reinicie o Ollama para liberar o tráfego dos containers Docker.
3. Download dos Modelos: Execute no terminal:
ollama pull qwen2.5:7b (ou qwen2.5:3b para máquinas mais modestas)
ollama pull nomic-embed-text

Fase 2: Instalação e Configuração do Projeto

1. Clonagem do Repositório:
git clone https://github.com/douglas-bsj/assistente-pessoal-hero.git
cd assistente-pessoal-hero
2. Configuração do Arquivo de Ambiente:
Copie .env.example para .env e personalize seu nome em JARVIS_USER_NAME=SeuNome.

Fase 3: Inicialização dos Containers

Execute no terminal raiz do projeto:
docker compose up --build -d
Aguarde o download e inicialização dos serviços jarvis-db e jarvis-core. Para acompanhar os logs de inicialização:
docker compose logs -f jarvis-core

Fase 4: Operação no HUD e Recursos

1. Acesso Web: Acesse **http://localhost:8000** no navegador e permita o microfone.
2. Controles de Áudio e Atalhos:
- **Barra de Espaço:** Pressione e segure para falar (Push-to-Talk).
- **Esc:** Corta a fala do assistente instantaneamente (Barge-In).
- **Mãos-Livres:** Habilite o modo contínuo de ativação por voz (VAD).

3. Gerenciamento de Memória (Hipocampo): Clique no botão **Hipocampo** para auditar, buscar ou apagar memórias salvas.

Fase 5: Manutenção e Resolução de Problemas

- **Redefinir banco de memórias do zero:** docker compose down -v && docker compose up -d
- **Economia de memória RAM:** Mude OLLAMA_CHAT_MODEL=qwen2.5:3b e WHISPER_MODEL=tiny no .env.
- **Headset P3 no Windows:** Selecione *Headset com microfone* no gerenciador de áudio para evitar captura acidental pelo microfone embutido.